



Modelagem Computacional no
Sertão Mineiro



PPGMCS
Programa de Pós-Graduação em
Modelagem Computacional e Sistemas

PREVISÃO MENSAL DE IRRADIÂNCIA GLOBAL HORIZONTAL EM LOCALIDADES DE FÁBRICAS DE VEÍCULOS ELÉTRICOS COM UMA APROXIMAÇÃO DO DEEPNPTS

Gustavo de Melo Nascimento¹ - g239679@dac.unicamp.br

Thales Wulfert Cabral¹ - t264377@dac.unicamp.br

Gustavo Fraidenraich¹ - gfraiden@unicamp.br

¹Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas – Campinas, SP, Brasil

Abstract. Este artigo apresenta um sistema para previsão mensal da Irradiância Global Horizontal (GHI) em dez localidades associadas a fábricas de veículos elétricos. Foram utilizados dados da National Solar Radiation Database, produto GOES Aggregated PSM v4, entre 2019 e 2024. As observações, coletadas em intervalos de 60 minutos e processadas como médias diárias, foram agregadas por mês civil, quantizadas em 128 níveis, normalizadas e organizadas em atributos temporais para prever o mês seguinte. O método proposto é uma aproximação experimental inspirada no DeepNPTS, que combina similaridade entre padrões históricos e ponderação por recência. A avaliação adotou divisão cronológica de 80% para treinamento e 20% para teste. Entre sete modelos, a aproximação obteve o menor erro médio: MAE de 12,96 W/m², RMSE de 16,39 W/m², R² de 0,916 e nRMSE de 8,10%. Em relação à RNN, melhor referência média, houve redução de 12,50% no MAE e 10,07% no RMSE.

Keywords: Irradiância solar, GHI, Previsão mensal, Séries temporais, DeepNPTS

1. INTRODUÇÃO

A expansão da geração fotovoltaica aumenta a necessidade de estimar antecipadamente a disponibilidade do recurso solar. Como a potência produzida depende da irradiância incidente, erros de previsão afetam o planejamento operacional, o dimensionamento de instalações e a integração da geração à rede (Antonanzas et al., 2016; Voyant et al., 2017; Yang et al., 2018). Este trabalho considera a Irradiância Global Horizontal (GHI), definida por

$$GHI = DHI + DNI \cos(\theta_z), \quad (1)$$

em que DHI é a irradiância difusa horizontal, DNI é a irradiância direta normal e θ_z é o ângulo zenital solar (Duffie e Beckman, 2013). A GHI reúne as componentes direta e difusa e permite comparar localidades sob a mesma referência física, em W/m² (Sengupta et al., 2018).

Em escala mensal, a agregação reduz oscilações meteorológicas de curta duração e evidencia sazonalidade e tendências do recurso solar. Entretanto, cada ano acrescenta somente doze observações, tornando a tarefa um problema de séries temporais curtas. Métodos tabulares e redes neurais são amplamente empregados na previsão solar (Sobri et al., 2018). Entre eles, o XGBoost representa relações não lineares por árvores impulsionadas (Chen e Guestrin, 2016), enquanto RNNs e LSTMs tratam dependências sequenciais (Hochreiter e Schmidhuber, 1997).

O Deep Non-Parametric Time Series Forecaster (DeepNPTS) aprende probabilidades de amostragem sobre observações históricas sem impor uma família paramétrica fixa à distribuição preditiva (Rangapuram et al., 2023). Essa reutilização de padrões observados é atraente quando há poucas amostras mensais. Assim, o objetivo deste estudo é avaliar um sistema inspirado nesse princípio para prever a GHI média do mês seguinte em dez localidades associadas a fábricas de veículos elétricos. A contribuição é uma comparação homogênea entre sete modelos, com o mesmo processamento, corte temporal e conjunto de métricas. O rótulo “DeepNPTS” empregado adiante identifica a aproximação experimental descrita na Seção 2, e não uma reprodução integral da arquitetura original.

2. METODOLOGIA

2.1 Dados e protocolo experimental

Foram utilizados dados da National Solar Radiation Database (NSRDB), atualmente mantida pelo National Laboratory of the Rockies (NLR, anteriormente NREL), no produto GOES Aggregated PSM v4 (National Laboratory of the Rockies, 2026). A consulta abrangeu 1 de janeiro de 2019 a 31 de dezembro de 2024, com intervalo de 60 minutos. O fluxo armazenou médias diárias e, posteriormente, calculou a média de cada mês civil.

As dez localidades são: BYD Camaçari, BMW San Luis Potosí, Ford Rouge, GM Factory Zero, Hyundai Metaplant Georgia, Lucid AMP 1 Casa Grande, Rivian Normal e as unidades Tesla de Fremont, Nevada e Texas. Cada série foi ordenada e verificada quanto a cobertura temporal, duplicidades, ausências, valores negativos e consistência geográfica. A GHI foi mantida em W/m^2 .

Após a criação dos atributos, cada localidade forneceu 60 exemplos supervisionados, com alvos entre janeiro de 2020 e dezembro de 2024. A divisão cronológica destinou 48 exemplos ao treinamento e 12 ao teste, correspondentes aos meses de 2024, sem embaralhamento. Cada entrada de teste utilizou apenas o histórico disponível até o instante da previsão, e os modelos permaneceram fixos durante o teste. A Tabela 1 resume as condições principais.

2.2 Pré-processamento e modelos

Os limites da quantização e da transformação min–max foram estimados somente com o conjunto de treinamento e reutilizados no teste. As defasagens e médias móveis formaram os pares $(X_{\ell,t}, y_{\ell,t+1})$, em que ℓ identifica a localidade. Os concorrentes foram configurados conforme os registros experimentais: XGBoost com 300 estimadores, profundidade 3 e taxa 0,05; MLP com camadas ocultas de 64 e 32 neurônios; e RNN/LSTM com 32 unidades recorrentes, camada densa de 16 neurônios e saída sigmoideal. As redes utilizaram Adam, taxa 0,001, MSE, 80 épocas e lote 32. A DilatedRNN experimental combinou ramos com dilatações 1, 2 e 4, e o DeepAR experimental empregou LSTM com saída gaussiana (Chang et al., 2017; Salinas et al., 2020).

Na aproximação do DeepNPTS, o vetor corrente é comparado aos históricos candidatos. Similaridade e recência definem os pesos usados na previsão pontual:

Tabela 1: Configuração do experimento mensal.

Item	Configuração
Dados	NSRDB/NLR, GOES Aggregated PSM v4, GHI em W/m ² , 2019–2024.
Previsão	Um mês à frente; 48 exemplos de treino e 12 de teste por localidade.
Pré-processamento	Quantização em 128 níveis e normalização min–max ajustadas somente no treino.
Atributos	Defasagens de 1, 2, 3 e 6 meses; médias móveis de 3, 6 e 12 meses.
Modelos	XGBoost, MLP, RNN, LSTM, DilatedRNN exp., DeepAR exp. e DeepNPTS aprox.
Reprodutibilidade	Semente 42; uma execução por modelo e localidade.

$$\hat{y}_{\ell,t+1} = \frac{\sum_{j \in \mathcal{H}_{\ell,t}} w_{t,j} y_{\ell,j+1}}{\sum_{j \in \mathcal{H}_{\ell,t}} w_{t,j}}, \quad (2)$$

$$w_{t,j} = \exp[-d(X_{\ell,t}, X_{\ell,j})/\tau] \gamma^{-j},$$

em que $\mathcal{H}_{\ell,t}$ reúne os históricos, $d(\cdot)$ é a distância euclidiana, $\tau = 0,08$ controla a concentração e $\gamma = 0,995$ pondera a recência. Foram considerados até $k = 80$ vizinhos, limitados aos 48 exemplos de treino. Ao contrário do DeepNPTS canônico, essa implementação não treina uma rede global nem otimiza um escore probabilístico: os pesos da Equação 2 são calculados diretamente em cada série.

2.3 Métricas e seleção

Sejam y_i a GHI real, $\hat{y}_i$ a previsão, $\bar{y}$ a média observada e n o número de meses de teste. Foram calculados MAE, MSE, RMSE, R^2 e nRMSE. Para concisão, as métricas centrais são

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|,$$

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (3)$$

$$\text{nRMSE}(\%) = 100 \text{RMSE} / \bar{y}.$$

O MAE em W/m² definiu o vencedor por ser diretamente interpretável e menos sensível a erros extremos do que o RMSE (Hyndman e Koehler, 2006). Para cada modelo m , calculou-se $\overline{\text{MAE}}_m$ entre as dez localidades; selecionou-se $m^* = \arg \min_m \overline{\text{MAE}}_m$.

3. RESULTADOS E DISCUSSÃO

A Tabela 2 apresenta as médias das métricas nas dez localidades, ordenadas pelo MAE. A aproximação do DeepNPTS obteve o menor MAE (12,96 W/m²), o menor RMSE (16,39 W/m²), o maior R^2 (0,916) e o menor nRMSE (8,10%). Portanto, a seleção pelo MAE não contradiz os demais indicadores.

Tabela 2: Métricas médias mensais dos modelos avaliados.

Modelo	MAE W/m ²	MSE W ² /m ⁴	RMSE W/m ²	R ²	nRMSE %
DeepNPTS aprox.	12,96	281,29	16,39	0,916	8,10
RNN	14,81	363,32	18,23	0,878	8,97
XGBoost	15,23	415,07	19,41	0,875	9,70
DilatedRNN exp.	15,25	380,90	18,73	0,878	9,29
MLP	16,13	412,61	19,70	0,861	9,58
LSTM	20,60	659,72	24,69	0,785	11,99
DeepAR exp.	61,02	5038,27	68,57	0,010	34,21

Em relação à RNN, melhor referência média, a aproximação reduziu o MAE em 12,50% e o RMSE em 10,07%. A diferença para o DeepAR experimental foi mais ampla: redução de 78,76% no MAE. Esse resultado sugere que a configuração probabilística adotada não se ajustou às séries mensais com apenas 48 exemplos de treinamento. A Figura 1 evidencia tanto a vantagem do método proposto quanto a distância do DeepAR em relação ao grupo principal.




Figura 1: MAE médio dos modelos nas dez localidades; valores menores indicam melhor desempenho.

A análise individual mostra que a aproximação venceu em cinco localidades: BMW San Luis Potosí, BYD Camaçari, Hyundai Metaplant Georgia, Rivian Normal e Tesla Texas. A RNN venceu em Ford Rouge, GM Factory Zero e Tesla Fremont; o XGBoost, em Lucid Casa Grande; e a DilatedRNN experimental, em Tesla Nevada. O melhor MAE do método proposto ocorreu na Tesla Texas (9,50 W/m²), e o pior, na BMW San Luis Potosí (18,65 W/m²).

Na Tesla Texas, a redução frente à MLP, melhor concorrente local, foi de 37,23%. Em contraste, o XGBoost obteve 5,61 W/m² na Lucid Casa Grande, contra 10,40 W/m² da aproximação. A Figura 2 confirma que o método é robusto em média, mas não domina todas as condições regionais.

Na série de Camaçari, ambos os métodos acompanharam a redução de GHI no meio do ano e a recuperação no último trimestre. A aproximação apresentou MAE de 13,85 W/m², ante 16,74 W/m² da RNN, uma redução de 17,24%. A vantagem decorreu do erro acumulado nos doze meses, não de superioridade em cada previsão isolada. Em conjunto, os resultados favorecem o reaproveitamento de padrões históricos quando a série é curta e sazonal; contudo, a avaliação com uma única divisão temporal e uma execução por modelo não quantifica a variabilidade entre inicializações ou diferentes períodos de teste.




Figura 2: MAE da aproximação do DeepNPTS e do melhor concorrente em cada localidade.

4. CONCLUSÕES

Este trabalho apresentou um sistema para previsão mensal de GHI baseado em uma aproximação experimental do DeepNPTS. O fluxo integrou aquisição, limpeza, agregação mensal, quantização, normalização, atributos temporais, divisão cronológica e comparação homogênea de sete modelos em dez localidades.

A aproximação foi a campeã geral, com MAE de 12,96 W/m², RMSE de 16,39 W/m², R^2 de 0,916 e nRMSE de 8,10%. Frente à RNN, melhor referência média, as reduções foram de 12,50% no MAE e 10,07% no RMSE. O método venceu em cinco localidades, mas sua superioridade não foi uniforme, indicando que características regionais ainda influenciam a escolha do modelo.

Os resultados sustentam a ponderação por similaridade e recência como alternativa competitiva para séries mensais curtas. Trabalhos futuros devem empregar validação temporal em múltiplas janelas, repetir os modelos estocásticos, incluir variáveis meteorológicas, avaliar horizontes superiores a um mês e implementar o DeepNPTS canônico com treinamento conjunto de séries relacionadas.

Agradecimentos. Os autores agradecem à FAPEMIG (processo OET-00243-26), à Universidade Estadual de Campinas (UNICAMP) e à Faculdade de Engenharia Elétrica e de Computação (FEEC) pelo apoio ao desenvolvimento deste projeto.

REFERÊNCIAS

- Antonanzas, J. et al. (2016), “Review of photovoltaic power forecasting”, *Solar Energy*, vol. 136, p. 78–111.
- Chang, S. et al. (2017), “Dilated recurrent neural networks”, *Advances in Neural Information Processing Systems*.
- Chen, T. e Guestrin, C. (2016), “XGBoost: A scalable tree boosting system”, *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, p. 785–794.
- Duffie, J.A. e Beckman, W.A. (2013), *Solar Engineering of Thermal Processes*, 4a ed., Wiley, Hoboken.
- Hochreiter, S. e Schmidhuber, J. (1997), “Long short-term memory”, *Neural Computation*, vol. 9, n. 8, p. 1735–1780.
- Hyndman, R.J. e Koehler, A.B. (2006), “Another look at measures of forecast accuracy”, *International Journal of Forecasting*, vol. 22, n. 4, p. 679–688.
- National Laboratory of the Rockies (2026), “GOES Aggregated: PSM v4 Download API”. Disponível em: <https://developer.nlr.gov/docs/solar/nsrdb/nsrdb-GOES-aggregated-v4-0-0-download/>. Acesso em: 14 jul. 2026.
- Rangapuram, S.S. et al. (2023), “Deep non-parametric time series forecaster”, *arXiv preprint arXiv:2312.14657*.
- Salinas, D.; Flunkert, V.; Gasthaus, J. e Januschowski, T. (2020), “DeepAR: Probabilistic forecasting with autoregressive recurrent networks”, *International Journal of Forecasting*, vol. 36, n. 3, p. 1181–1191.
- Sengupta, M. et al. (2018), “The National Solar Radiation Data Base (NSRDB)”, *Renewable and Sustainable Energy Reviews*, vol. 89, p. 51–60.
- Sobri, S.; Koohi-Kamali, S. e Rahim, N.A. (2018), “Solar photovoltaic generation forecasting methods: A review”, *Energy Conversion and Management*, vol. 156, p. 459–497.
- Voyant, C. et al. (2017), “Machine learning methods for solar radiation forecasting: A review”, *Renewable Energy*, vol. 105, p. 569–582.
- Yang, D. et al. (2018), “History and trends in solar irradiance and PV power forecasting”, *Solar Energy*, vol. 168, p. 60–101.