

Previsão Horária de Irradiância Global Horizontal em Localidades Associadas a Fábricas de Veículos Elétricos com TimesNet

Gustavo de Melo Nascimento, Thales Wulfert Cabral e Gustavo Fraidenraich

Resumo—Este artigo avalia uma adaptação compacta do TimesNet para prever, em escala horária, a irradiância global horizontal (GHI) em dez localidades associadas a fábricas de veículos elétricos. Usam-se 336 h de histórico para prever diretamente as 72 h seguintes, avaliando-se também os prefixos de 24 e 48 h. As séries da National Solar Radiation Database (NSRDB) cobrem 2019–2024 e agregam registros de 30 min em médias horárias. A divisão cronológica destina 2019–2022 ao treinamento, 2023 à seleção do número de épocas, 2019–2023 ao ajuste final e 2024 ao teste retrospectivo. Comparam-se TimesNet, uma rede *Long Short-Term Memory* (LSTM), persistência diária e sazonal ingênuo anual sob as mesmas origens e regras físicas de pós-processamento. Em 72 h, o TimesNet obteve raiz do erro quadrático médio (RMSE) macro de 101,04 W/m², enquanto a LSTM obteve 104,68 W/m², o que corresponde a uma redução relativa de 3,48%. O TimesNet também apresentou RMSE menor que o da LSTM nos demais horizontes e que o das duas referências nos três horizontes. Os resultados limitam-se às localidades, aos anos e ao protocolo estudados.

Palavras-chave—Irradiância solar, GHI, previsão de múltiplos passos, séries temporais, TimesNet.

I. INTRODUÇÃO

Previsões de irradiância subsidiam o dimensionamento, o planejamento e a operação energética, mas sua utilidade depende da resolução, do horizonte e das informações disponíveis na origem [1]–[3]. Em resolução horária e para horizontes de vários dias, é preciso representar o ciclo noite–dia e as variações meteorológicas que alteram a amplitude e a forma dos perfis diurnos.

A literatura combina redes recorrentes, modelos convolucionais e mecanismos de atenção, com diferentes entradas, horizontes e protocolos [2]; isso dificulta separar o efeito da arquitetura dos efeitos das partições, origens e pós-processamento. O TimesNet identifica períodos dominantes, reorganiza a sequência em duas dimensões e aplica convoluções 2D às variações dentro e entre períodos [4].

Investiga-se se uma adaptação compacta do TimesNet reduz o erro em relação a uma LSTM e referências temporais quando todos os métodos compartilham dados, origens e tratamento físico. Avaliam-se 336 h de contexto, uma saída direta de 72 h e seus prefixos de 24 e 48 h. As contribuições são: (i) um modelo global para dez localidades com *embedding* do identificador; (ii) uma versão compacta do TimesNet para a previsão univariada de GHI; (iii) a comparação de quatro

métodos sob o mesmo protocolo cronológico, por horizonte, passo e localidade; e (iv) a quantificação do efeito das restrições físicas. As fábricas definem apenas os pontos geográficos, sem uso de dados industriais.

A. Fundamentação e trabalhos relacionados

A GHI é a irradiância total em uma superfície horizontal: $GHI = DHI + DNI \cos(\theta_z)$, em que DHI e DNI são as componentes difusa horizontal e direta normal, e θ_z é o ângulo zenital [5]. O alvo é a GHI média horária da NSRDB em W/m² [6], não energia acumulada nem potência fotovoltaica. Seu ciclo diário é modulado pela sazonalidade e pelas condições atmosféricas, gerando variações intraperíodo e interperíodo.

A previsão solar abrange estatística, aprendizado de máquina e redes neurais [2], [7]. Referências ingênuas indicam se a complexidade adicional traz ganho, e a LSTM constitui um comparador recorrente consolidado [8].

Na resolução horária, redes densas e LSTM já foram usadas em previsão de múltiplos passos [9], e o TimesNet, em séries solares multivariadas e diferentes horizontes [10]. Em escala mensal, Cabral, Fraidenraich e Capretz avaliaram modelos de linguagem e variantes de Transformer em 40 localidades e horizonte de cinco anos [11]. As escalas distintas impedem comparar diretamente os erros: resolução, horizonte e protocolo definem problemas experimentais diferentes.

Este estudo prevê diretamente 72 h em resolução horária, usa apenas o histórico de GHI como entrada dinâmica, acrescenta o identificador estático da localidade e reserva um ano completo para teste. A contribuição é configurar e avaliar experimentalmente o TimesNet, não propor sua arquitetura.

II. METODOLOGIA E PROTOCOLO EXPERIMENTAL

A Fig. 1 resume o procedimento. Cada coordenada define uma série S_ℓ , $\ell \in \mathcal{L}$. A auditoria verifica cobertura, ordenação, duplicidades, lacunas e valores inválidos; pares consecutivos de 30 min são então convertidos em médias horárias. O índice permanece em UTC e recebe também uma representação em tempo-padrão local com deslocamento fixo. Para cada origem diária t às 00 h locais, constroem-se $\mathbf{x}_{\ell,t} = (y_{\ell,t-336}, \dots, y_{\ell,t-1})$ e $\mathbf{y}_{\ell,t} = (y_{\ell,t}, \dots, y_{\ell,t+71})$, sem informação posterior à origem.

As 336 h de entrada correspondem a 14 ciclos diários completos e a duas semanas, enquanto as 72 h de saída cobrem três dias. As origens diárias reduzem a redundância em comparação com origens a cada hora, mas os alvos de origens




Figura 1. Fluxo metodológico desde a aquisição dos dados horários até a avaliação. As coordenadas das fábricas definem as séries. Todos os métodos são avaliados nas mesmas origens, alvos e partições temporais e submetidos às mesmas regras de pós-processamento.

consecutivas ainda se sobrepõem. A estratégia direta estima todos os passos conjuntamente e evita realimentar previsões como entradas; em contrapartida, exige que a cabeça do modelo aprenda de uma vez a estrutura de erro ao longo das 72 h.

TimesNet e LSTM compartilham parâmetros entre localidades e geram as 72 saídas em uma passagem. A persistência repete o último perfil diário e a referência sazonal usa a mesma hora local do ano anterior:

$$\hat{y}_{\ell,t+h-1}^{\text{per}} = y_{\ell,t-24+((h-1) \bmod 24)}, \quad (1)$$

$$\hat{y}_{\ell,t+h-1}^{\text{saz}} = y_{\ell,\text{anoAnt}(t+h-1)}, \quad h = 1, \dots, 72. \quad (2)$$

em que $\text{anoAnt}(\cdot)$ preserva mês, dia e hora, com 29 de fevereiro mapeado para 28 de fevereiro. Após a inversão da normalização, o pós-processamento aplica o truncamento em zero (*clipping*) aos valores negativos e zera a previsão quando a elevação solar no centro do intervalo, calculada com *pvlb* [12], não é positiva:

$$\hat{y}_{\ell,t+h-1}^{\text{pos}} = \max(0, \hat{y}_{\ell,t+h-1}^{\text{inv}}) \mathbb{I}(\alpha_{\ell,t+h-1} > 0^\circ). \quad (3)$$

A regra usa apenas geometria determinística e é comum aos quatro métodos. Como o alvo é uma média horária, a classificação pelo centro do intervalo é aproximada. Avaliam-se os prefixos de 24, 48 e 72 h por localidade e por passo, além da média macro e do subconjunto com elevação positiva.

A. Arquitetura TimesNet adaptada

Seja $\mathbf{X}_b^{(r)} \in \mathbb{R}^{T \times d}$ a representação da amostra b no bloco r , em que T é o comprimento temporal e d é a dimensão latente. A transformada rápida de Fourier (FFT) identifica os k índices espectrais não nulos f_i de maior amplitude média no lote; cada índice define o período discreto $p_i = \lfloor T/f_i \rfloor$. Após preenchimento, a sequência é reorganizada em $c_i = \lceil T/p_i \rceil$ ciclos de p_i posições e processada por convoluções 2D multiescala. Denotando por $a_{b,f_i}^{(r)}$ a amplitude da amostra b no índice f_i , as saídas $\mathbf{Z}_{b,i}^{(r)}$ são combinadas por

$$w_{b,i}^{(r)} = \frac{\exp(a_{b,f_i}^{(r)})}{\sum_{j=1}^k \exp(a_{b,f_j}^{(r)})}, \quad \mathbf{X}_b^{(r+1)} = \mathbf{X}_b^{(r)} + \sum_{i=1}^k w_{b,i}^{(r)} \mathbf{Z}_{b,i}^{(r)}. \quad (4)$$

Nesta adaptação, uma convolução circular unidimensional de núcleo 3 projeta a entrada univariada; somam-se codificação posicional e *embedding* estático do identificador da localidade. O TimesBlock contém dois bancos Inception separados por uma ativação GELU (*Gaussian Error Linear Unit*); a saída residual do bloco é seguida por normalização em camada. Por fim, uma projeção direta transforma as 336 posições nas 72 estimativas. O mecanismo periódico segue o TimesNet original [4]; a configuração compacta é detalhada a seguir.

Antes dessa projeção, cada janela já transformada pela escala min-max é padronizada por sua própria média μ_b e desvio-padrão σ_b ; a operação inversa é aplicada à saída do modelo:

$$\tilde{\mathbf{x}}_b = \frac{\mathbf{x}_b - \mu_b}{\sqrt{\sigma_b^2 + \epsilon}}, \quad \hat{\mathbf{y}}_b = \hat{\tilde{\mathbf{y}}}_b \sqrt{\sigma_b^2 + \epsilon} + \mu_b. \quad (5)$$

Essa etapa preserva o nível e a escala observados na própria origem, sem usar o alvo. A normalização min-max externa mantém comparabilidade entre localidades durante a otimização, enquanto a Eq. (5) atenua mudanças locais de nível. O *embedding* permite especialização por sítio dentro de um único modelo global, mas não representa coordenadas e, portanto, não oferece extrapolação direta para uma localidade não vista.

B. Dados e recorte geográfico

O produto GOES Aggregated PSM v4.0.0 da NSRDB combina informações de satélite e modelos físicos; trata-se, portanto, de uma referência modelada, não de medições em solo [6], [13]. Os arquivos HDF5 de 30 min foram convertidos em médias horárias. Cada uma das dez séries contém 52.608 observações referentes ao período de 2019 a 2024, totalizando 526.080 valores. A Tabela I registra os pontos de grade e os deslocamentos locais usados.

C. Partições temporais e normalização

A divisão estritamente cronológica contém 14.450 janelas em 2019–2022 para treinamento, 3.630 em 2023 para validação e 3.630 (363 por localidade) em 2024 para teste. Após selecionar o número de épocas, cada rede é reinicializada e ajustada em 18.100 janelas de 2019–2023. Os alvos permanecem integralmente no respectivo período. O teste termina na origem local correspondente a 28 de dezembro, pois a origem seguinte exigiria dados UTC de 2025 em parte das localidades.

O teste é retrospectivo e deslizante: observações já disponíveis em cada origem de 2024 podem compor o contexto, sem

Tabela I
PONTOS DE GRADE DA NSRDB. LATITUDE E LONGITUDE EM GRAUS; DESLOCAMENTOS UTC EM HORAS.

Localidade	Lat.	Lon.	Célula	UTC	Localidade	Lat.	Lon.	Célula	UTC
BMW San Luis Potosí	21,97	-100,86	593265	-6	Lucid Casa Grande	32,85	-111,78	329823	-7
BYD Camaçari	-12,67	-38,30	2000061	-3	Rivian Normal	40,49	-89,06	871382	-6
Ford Rouge	42,29	-83,18	995809	-5	Tesla Fremont	37,49	-121,94	144390	-8
GM Factory Zero	42,37	-83,06	998284	-5	Tesla Nevada	39,53	-119,42	184510	-8
Hyundai Georgia	32,17	-81,46	1031588	-5	Tesla Texas	30,21	-97,62	681461	-6

Tabela II
RESUMO DAS REDES NEURAIS AVALIADAS.

Característica	LSTM	TimesNet
Representação principal	32 estados	$d_{\text{model}} = 8$
Profundidade	1 camada	1 TimesBlock
Embedding local	8	8
Saída direta	72 h	72 h
Parâmetros treináveis	7.512	27.009
Épocas selecionadas	22	14

novo ajuste das redes. Os resultados de 24 e 48 h são prefixos da mesma saída de 72 h. A normalização min-max é estimada por localidade em 2019–2022 na seleção e em 2019–2023 no ajuste final; valores posteriores não são limitados ao intervalo $[0, 1]$. O TimesNet ainda padroniza cada janela internamente. Todos os métodos retornam à escala física antes da Eq. (3).

D. Modelos e hiperparâmetros

A LSTM usa 32 unidades, concatena ao estado final o *embedding* de localidade de dimensão 8 e não aplica *dropout*; foram selecionadas 22 épocas. O TimesNet usa $d_{\text{model}} = 8$, $d_{\text{ff}} = 16$, um TimesBlock, $k = 3$, núcleos 1×1 e 3×3 , *dropout* 0,1, *embedding* de dimensão 8 e $\epsilon = 10^{-5}$ como estabilizador da padronização por janela; foram selecionadas 14 épocas. Em ambos, Adam minimiza o erro quadrático médio (MSE) na escala normalizada, com taxa de aprendizado 10^{-3} , *weight decay* 10^{-5} , tamanho de lote 128, limite de 30 épocas e paciência de cinco épocas. As configurações foram fixadas antes do teste e toda a execução usou uma única semente aleatória (42).

O número de épocas corresponde à época em que se observou o menor MSE de validação antes da parada antecipada. No ajuste final, cada rede foi reinicializada com a mesma semente e treinada exatamente por esse número de épocas, sem reutilizar o estado da seleção. A Tabela II mostra também que o TimesNet compacto tem 3,60 vezes o número de parâmetros da LSTM; o ganho de erro deve, portanto, ser interpretado junto desse aumento de capacidade.

E. Métricas

Sejam $\mathcal{L}$ o conjunto das dez localidades, $\ell \in \mathcal{L}$ uma localidade, m o modelo, $q \in \{24, 48, 72\}$ o horizonte avaliado e $i \in \{1, \dots, n_{\ell,q}\}$ o índice de um par origem-passo. Denotam-se por $y_{\ell,i}$ a GHI de referência, $\hat{y}_{\ell,i,m}$ a previsão após o pós-processamento, $\bar{y}_{\ell,q}$ a média dos alvos e $e_{\ell,i,m} = y_{\ell,i} - \hat{y}_{\ell,i,m}$ o erro. Calculam-se a raiz do erro quadrático médio (RMSE), o erro absoluto médio (MAE), o RMSE normalizado (nRMSE) e o coeficiente de determinação (R^2):

$$\text{RMSE}_{\ell,m,q} = \sqrt{n_{\ell,q}^{-1} \sum_i e_{\ell,i,m}^2}, \quad (6)$$

$$\text{MAE}_{\ell,m,q} = n_{\ell,q}^{-1} \sum_i |e_{\ell,i,m}|, \quad (7)$$

$$\text{nRMSE}_{\ell,m,q}(\%) = 100 \text{RMSE}_{\ell,m,q} / \bar{y}_{\ell,q}, \quad (8)$$

$$R_{\ell,m,q}^2 = 1 - \frac{\sum_i e_{\ell,i,m}^2}{\sum_i (y_{\ell,i} - \bar{y}_{\ell,q})^2}. \quad (9)$$

O RMSE é o critério primário; o MAE mantém interpretação direta em W/m^2 [14]; o nRMSE normaliza o RMSE pela GHI média local; e o R^2 compara o desempenho do modelo ao de um preditor constante. Cada métrica é calculada primeiro por localidade e depois resumida pela média macro não ponderada, evitando que uma localidade domine a comparação. Para 363 origens por localidade, os horizontes de 24, 48 e 72 h contêm, respectivamente, 87.120, 174.240 e 261.360 pares alvo-previsão no conjunto das dez séries. Esses pares quantificam erro, mas não são réplicas independentes devido à sobreposição entre janelas. O conjunto de teste não foi usado para selecionar configurações nem alterar o procedimento.

III. RESULTADOS E DISCUSSÃO

A. Desempenho agregado por horizonte

A Tabela III reúne as métricas macro dos quatro métodos nos três prefixos da previsão de 72 h e permite verificar se o ordenamento se mantém com o aumento do horizonte.

Em 24, 48 e 72 h, os valores de RMSE do TimesNet foram 97,21, 100,26 e 101,04 W/m^2 , contra 100,01, 103,00 e 104,68 W/m^2 da LSTM: reduções de 2,80%, 2,66% e 3,48%. O mesmo ordenamento entre as duas redes foi observado para MAE, nRMSE e R^2 .

Em relação à persistência diária, as reduções de RMSE do TimesNet foram 20,46%, 21,89% e 23,06%; em relação ao sazonal ingênuo, foram 31,92%, 29,79% e 29,22%. Do prefixo de 24 h ao de 72 h, o RMSE cresceu 3,94% no TimesNet e 4,67% na LSTM. Como os prefixos provêm de uma única saída direta, essa variação descreve a dificuldade associada à ampliação do horizonte, e não a propagação recursiva de previsões.

Das 261.360 previsões de 72 h, 130.764 pertencem ao subconjunto com elevação solar positiva. Nesse recorte, o TimesNet obteve RMSE de 142,80 W/m^2 , nRMSE de 35,67% e R^2 de 0,739; o RMSE da LSTM foi 147,94 W/m^2 . É esperado que o RMSE diurno seja maior do que o calculado considerando

Tabela III
MÉDIAS MACRO NO TESTE RETROSPECTIVO DE 2024. RMSE E MAE EM W/m^2 ; nRMSE EM %.

24 h					48 h					72 h				
Modelo	RMSE	MAE	nRMSE	R^2	Modelo	RMSE	MAE	nRMSE	R^2	Modelo	RMSE	MAE	nRMSE	R^2
Persist.	122,21	52,58	61,28	0,801	Persist.	128,35	56,16	64,34	0,781	Persist.	131,32	58,11	65,77	0,771
Sazonal	142,78	65,91	71,19	0,734	Sazonal	142,79	65,92	71,21	0,734	Sazonal	142,76	65,90	71,20	0,734
LSTM	100,01	50,91	49,95	0,869	LSTM	103,00	52,79	51,39	0,862	LSTM	104,68	53,39	52,17	0,858
TimesNet	97,21	49,08	48,54	0,876	TimesNet	100,26	51,86	49,99	0,869	TimesNet	101,04	52,21	50,35	0,867

Tabela IV
RMSE POR LOCALIDADE EM 72 H. VALORES EM W/m^2 ; Δ É A REDUÇÃO RELATIVA DO TIMESNET EM RELAÇÃO À LSTM.

Localidade	TimesNet	LSTM	Δ (%)
Lucid Casa Grande	74,35	79,59	6,59
Tesla Fremont	76,67	81,34	5,75
Tesla Nevada	82,72	87,15	5,09
BMW S. L. Potosí	97,70	100,29	2,58
BYD Camaçari	106,56	106,81	0,23
Tesla Texas	113,46	117,13	3,13
Ford Rouge	113,98	118,98	4,20
Hyundai Georgia	114,53	118,01	2,95
Rivian Normal	115,09	116,94	1,59
GM Factory Zero	115,36	120,59	4,34

todas as horas, pois as horas noturnas, predominantemente nulas, tornam a tarefa agregada menos exigente.

As diferenças entre as redes são moderadas e descritivas: não há ablação que as atribua à transformação 1D–2D, e o uso de uma única semente não permite estimar a variabilidade do treinamento. Os resultados mostram consistência interna neste protocolo, mas não constituem um teste de superioridade estatística.

Na Fig. 2(a), o erro inicial próximo de zero e a não monotonicidade decorrem das origens à meia-noite e da alternância entre horas diurnas e noturnas. O TimesNet permaneceu abaixo da LSTM a partir do prefixo de 6 h. No painel (b), seu RMSE foi inferior nas dez localidades, logo a diferença macro não resulta de uma única localidade.

B. Desempenho por localidade

Em 72 h, o RMSE do TimesNet variou de 74,35 W/m^2 em Lucid Casa Grande a 115,36 W/m^2 em GM Factory Zero e foi inferior ao da LSTM nas dez localidades. O nRMSE variou de 30,02% a 71,40%, evidenciando heterogeneidade entre as localidades avaliadas.

A redução do TimesNet em relação à LSTM teve mediana de 3,67% e variou de 0,23% em BYD Camaçari a 6,59% em Lucid Casa Grande. Assim, o sinal da diferença foi espacialmente consistente, embora sua magnitude tenha sido pequena em Camaçari. A amplitude dos erros absolutos e normalizados também indica que um único valor macro não caracteriza igualmente todos os regimes climáticos.

C. Exemplo de previsão e pós-processamento

A Fig. 3 mostra a primeira origem de teste da BYD Camaçari, escolhida por ordem cronológica, e não por desempenho favorável. A janela reúne 336 h de histórico e 72 h de

previsão; as curvas exibidas permitem inspecionar a coerência das transições diárias.

No horizonte de 72 h, o TimesNet gerou 261.360 previsões brutas nas dez localidades, das quais 109.295 (41,82%) eram negativas. Entre as previsões negativas, 108.766 (99,52%) ocorreram fora do período diurno e 529 durante ele. Portanto, esses valores concentram-se nas horas em que a saída fisicamente esperada está próxima de zero.

O RMSE macro foi 101,199 W/m^2 na saída bruta, 101,035 W/m^2 após o truncamento e 101,041 W/m^2 após a máscara. A redução líquida de 0,16% decorreu do truncamento; isoladamente, a máscara elevou o RMSE em 0,006 W/m^2 . Ela zerou 21.830 estimativas que permaneceram positivas após o truncamento; contudo, a média da GHI de referência nessas horas foi 0,85 W/m^2 . Esse resíduo decorre de intervalos que atravessam o nascer ou o pôr do sol e explica por que classificar somente pelo centro da hora pode piorar ligeiramente a métrica.

D. Validade e limitações

A evidência é retrospectiva e espacialmente restrita: o teste cobre apenas 2024, as dez localidades não formam amostra aleatória e as origens sobrepostas não podem ser tratadas como independentes. A NSRDB é uma referência modelada, o deslocamento UTC fixo ignora o horário de verão e os modelos não recebem meteorologia futura.

Do ponto de vista experimental, as configurações não resultam de busca ampla e o uso de uma única semente não permite estimar a variabilidade do treinamento. A máscara baseada no centro da hora é aproximada, e a comparação entre duas redes e duas referências não sustenta conclusões sobre outras classes de modelos. Portanto, a extrapolação para outras regiões, medições em solo, geração fotovoltaica, operação industrial ou horizonte de 168 h requer nova validação.

Há ainda duas restrições de interpretação. Primeiro, o *embedding* aprende identificadores das dez séries e não uma função contínua de latitude e longitude; avaliar um ponto novo exigiria novo ajuste ou uma representação geográfica apropriada. Segundo, as origens diárias compartilham até 48 h de alvos, de modo que testes que suponham erros independentes superestimariam a quantidade efetiva de evidência. Intervalos de confiança futuros devem usar blocos temporais e repetir o treinamento com várias sementes.

IV. CONCLUSÕES

Este trabalho investigou se uma adaptação compacta do TimesNet melhora a previsão horária de GHI em comparação




Figura 2. RMSE após o pós-processamento no teste de 2024. (a) Evolução do RMSE macro para cada prefixo da previsão, com destaque para 24, 48 e 72 h. (b) Comparação entre TimesNet e LSTM por localidade no horizonte de 72 h, com os sítios ordenados pelo erro do TimesNet.




Figura 3. Primeira origem de teste da BYD Camaçari: histórico de 336 h, referência da NSRDB, previsão bruta e previsão pós-processada nas 72 h seguintes.

com uma LSTM e duas referências temporais, sob um protocolo cronológico comum com 336 h de entrada e 72 h de saída.

Em 72 h, o TimesNet obteve RMSE macro de 101,04 W/m², ante 104,68 W/m² da LSTM, o que corresponde a uma redução relativa de 3,48%. O TimesNet também apresentou RMSE menor que o da LSTM em 24 e 48 h e que o das duas referências nos três horizontes, dentro do recorte estudado.

Em conjunto, os resultados indicam uma vantagem moderada e consistente do TimesNet nos horizontes e localidades avaliados, sem demonstrar superioridade universal nem isolar o efeito causal da transformação 1D–2D. O truncamento em zero garantiu a não negatividade das previsões; o efeito da máscara baseada no centro da hora foi desprezível e motiva a avaliação de uma regra que considere a hora inteira. Trabalhos futuros devem incluir múltiplas sementes, novas localidades, avaliação prospectiva, horizonte de 168 h, meteorologia exógena e incerteza.

REFERÊNCIAS

- [1] J. Antonanzas et al., “Review of photovoltaic power forecasting,” *Solar Energy*, vol. 136, pp. 78–111, 2016, doi: 10.1016/j.solener.2016.06.069.
- [2] C. Voyant et al., “Machine learning methods for solar radiation forecasting: A review,” *Renewable Energy*, vol. 105, pp. 569–582, 2017, doi: 10.1016/j.renene.2016.12.095.
- [3] D. Yang et al., “History and trends in solar irradiance and PV power forecasting: A preliminary assessment and review using text mining,” *Solar Energy*, vol. 168, pp. 60–101, 2018, doi: 10.1016/j.solener.2017.11.023.
- [4] H. Wu, T. Hu, Y. Liu, H. Zhou, J. Wang, and M. Long, “TimesNet: Temporal 2D-variation modeling for general time series analysis,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2023. [Online]. Available: https://openreview.net/forum?id=ju_Uqw384Oq.
- [5] J. A. Duffie and W. A. Beckman, *Solar Engineering of Thermal Processes*, 4th ed. Hoboken, NJ, USA: Wiley, 2013.
- [6] M. Sengupta et al., “The National Solar Radiation Data Base (NSRDB),” *Renewable and Sustainable Energy Reviews*, vol. 89, pp. 51–60, 2018, doi: 10.1016/j.rser.2018.03.003.
- [7] C. Voyant et al., “Benchmarks for solar radiation time series forecasting,” *Renewable Energy*, vol. 191, pp. 747–762, 2022, doi: 10.1016/j.renene.2022.04.065.
- [8] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [9] G. Guariso, G. Nunnari, and M. Sangiorgio, “Multi-step solar irradiance forecasting and domain adaptation of deep neural networks,” *Energies*, vol. 13, no. 15, Art. no. 3987, 2020, doi: 10.3390/en13153987.
- [10] Y. Zhu, M. Li, X. Ma, Y. Wang, G. Li, Y. Zhang, Y. Liu, and R. H. E. Hassanien, “Solar irradiance prediction with variable time lengths and multi-parameters in full climate conditions based on photovoltaic greenhouse,” *Energy Conversion and Management*, vol. 315, Art. no. 118758, 2024, doi: 10.1016/j.enconman.2024.118758.
- [11] T. W. Cabral, G. Fraidenraich, and M. A. M. Capretz, “Can large language models predict solar irradiance in the long term?,” *Solar Energy*, vol. 317, Art. no. 114964, 2026, doi: 10.1016/j.solener.2026.114964.
- [12] K. S. Anderson, C. W. Hansen, W. F. Holmgren, A. R. Jensen, M. A. Mikofski, and A. Driesse, “pvlb python: 2023 project update,” *Journal of Open Source Software*, vol. 8, no. 92, Art. no. 5994, 2023, doi: 10.21105/joss.05994.
- [13] National Laboratory of the Rockies, “GOES Aggregated PSM v4 Download API,” 2026. [Online]. Available: <https://developer.nlr.gov/docs/solar/nsrdb/nsrdb-GOES-aggregated-v4-0-0-download/>. Accessed: Jul. 30, 2026.
- [14] R. J. Hyndman and A. B. Koehler, “Another look at measures of forecast accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: 10.1016/j.ijforecast.2006.03.001.