

Avaliação do DeepNPTS e de Modelos de Referência para Previsão Mensal de Irradiância Global Horizontal em Localidades de Fábricas de Veículos Elétricos

Gustavo de Melo Nascimento, Thales Wulfert Cabral e Gustavo Fraidenraich

Resumo—Este artigo avalia o Deep Non-Parametric Time Series Forecaster (DeepNPTS) na previsão mensal de Irradiância Global Horizontal (GHI), com horizonte de um mês, em dez localidades. Dados da National Solar Radiation Database de 2019–2024 são agregados por mês, normalizados e quantizados com parâmetros pré-teste. O DeepNPTS discreto do GluonTS é comparado a três referências simples e seis modelos aprendidos. O protocolo retrospectivo utiliza 48 alvos de treinamento, 12 origens *walk-forward* de teste por localidade, cinco sementes e parâmetros fixos durante o teste. A climatologia obteve o menor macro-MAE, 12,07 W/m²; o DeepNPTS obteve 17,70 W/m², ficou em 9º lugar entre 10 métodos e superou apenas a persistência. Em relação ao DeepAR, o DeepNPTS teve maior CRPS e intervalos 4,10 vezes mais largos, embora sua cobertura tenha ficado mais próxima do nível nominal de 90%. Os resultados se restringem à janela retrospectiva estudada.

Palavras-chave—Irradiância solar, GHI, previsão probabilística, séries temporais, DeepNPTS.

I. INTRODUÇÃO

A disponibilidade do recurso solar condiciona a produção fotovoltaica e influencia decisões de dimensionamento, planejamento e operação energética. Previsões de irradiância podem reduzir a incerteza associada a essas decisões, mas sua formulação depende do horizonte, da resolução e das informações meteorológicas disponíveis [1]–[3].

Este trabalho considera a Irradiância Global Horizontal (GHI), a irradiância total incidente em uma superfície horizontal. Em termos das componentes direta e difusa,

$$GHI = DHI + DNI \cos(\theta_z), \quad (1)$$

em que DHI é a irradiância difusa horizontal, DNI é a irradiância direta normal e θ_z é o ângulo zenital solar [4]. A GHI é empregada por representar, em W/m², a disponibilidade solar sobre o plano horizontal e por integrar produtos padronizados da National Solar Radiation Database (NSRDB) [5]. A variável-alvo deste estudo é a média mensal de GHI, não energia nem produção fotovoltaica.

A previsão de uma série mensal com horizonte de um mês pode apoiar comparações de localidades e análises preliminares

Os autores são da Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas, Campinas, SP, Brasil. E-mails: g239679@dac.unicamp.br, t264377@dac.unicamp.br e gfraiden@unicamp.br.

de planejamento. A agregação mensal atenua flutuações intradiárias e evidencia a sazonalidade, mas fornece apenas doze observações por ano [1], [6]. Nesse regime, modelos flexíveis devem ser confrontados com referências sazonais simples.

A literatura de previsão solar abrange métodos estatísticos, aprendizado de máquina e redes neurais [2], [7]. Neste estudo, XGBoost [8], Perceptron Multicamadas (MLP) [9], Rede Neural Recorrente (RNN) [10], Long Short-Term Memory (LSTM) [11] e DilatedRNN [12] são os modelos aprendidos pontuais. Persistência, sazonal ingênuo e climatologia mensal são as referências simples.

Modelos globais compartilham parâmetros entre séries relacionadas. O DeepAR aprende uma distribuição preditiva por meio de uma rede autorregressiva global [13]. O DeepNPTS também explora séries relacionadas, mas sua variante discreta aprende probabilidades sobre os valores do contexto, sem fixar uma família paramétrica para a distribuição preditiva [14]. Essa característica motiva sua avaliação neste conjunto de séries curtas, mas não garante maior acurácia em qualquer aplicação.

O objetivo é verificar se o DeepNPTS discreto de [14], implementado no GluonTS, biblioteca descrita em [15], supera referências sazonais e modelos aprendidos na previsão da GHI média do mês seguinte. Todos usam os mesmos alvos e origens temporais, embora as entradas respeitem cada arquitetura, como detalhado na Seção II. As fábricas definem somente os pontos geográficos; não são usados dados de carga, geração ou operação industrial.

A. Principais contribuições

As contribuições são: (i) avaliação do DeepNPTS discreto como modelo global das dez séries relacionadas; (ii) comparação com três referências simples e seis modelos aprendidos sob as mesmas origens temporais; (iii) protocolo auditável com transformações pré-teste, cinco sementes e métricas pontuais e probabilísticas; e (iv) interpretação descritiva das limitações de uma janela retrospectiva curta, sem alegação de pioneirismo ou superioridade universal.

O restante do artigo está organizado da seguinte forma. A Seção II descreve o sistema e o protocolo; a Seção III apresenta a configuração e as métricas; a Seção IV discute os resultados; e a Seção V reúne as conclusões.




Figura 1. Fluxo do sistema: séries relacionadas, auditoria e agregação, transformação e representações específicas de cada arquitetura, ajuste global, teste retrospectivo e avaliação.

II. SISTEMA E MÉTODO EXPERIMENTAL

A Fig. 1 resume o fluxo, cujos blocos são descritos na mesma ordem.

Estágio (a) – dados. Cada localidade $\ell \in \mathcal{L}$ fornece uma série diária S_ℓ . As dez séries possuem a mesma variável e frequência, mas escalas e sazonalidades locais distintas.

Estágio (b) – auditoria e agregação. O sistema verifica datas, duplicidades, lacunas, valores não finitos e GHI negativa e calcula a média de cada mês civil. Os arquivos preservados contêm médias diárias derivadas de consultas com intervalo de 60 minutos; as respostas horárias brutas não foram preservadas e não podem ser reconstituídas a partir dessas médias.

Estágio (c) – transformação e representações. Para cada localidade, os limites min-max são estimados sem alvos do teste. Valores fora desses limites são saturados em $[0, 1]$ e quantizados uniformemente. Essa discretização é uma escolha experimental do pipeline, não um requisito do DeepNPTS. Modelos tabulares recebem 12 defasagens, médias móveis, calendário e codificação da localidade; redes recorrentes recebem a sequência cronológica e covariáveis separadas, concatenadas à representação temporal antes da camada densa; DeepNPTS e DeepAR recebem as séries transformadas e a categoria estática. Assim, alvos e origens são comuns, mas as entradas respeitam cada arquitetura.

Estágio (d) – ajuste. Para cada modelo aprendido e semente, há um único modelo final global, compartilhado pelas dez localidades; não é ajustado um modelo por fábrica. Quando aplicável, a complexidade é escolhida em uma validação cronológica e o modelo é reinicializado e reajustado em todo o período pré-teste. As referências simples não têm ajuste conjunto.

Estágio (e) – teste. Em cada origem, o histórico inclui somente meses já disponíveis e o mês seguinte é previsto. O valor de referência de um mês de 2024 integra o contexto da origem seguinte, mas os parâmetros permanecem fixos. Portanto, o protocolo não prevê os doze meses conjuntamente em dezembro de 2023.

Estágio (f) – escala física e avaliação. As saídas são invertidas para W/m^2 . Na inversão aplica-se apenas o piso físico de zero, sem corte superior no máximo do treinamento; logo, erros e caudas acima desse máximo permanecem representados nos modelos capazes de extrapolar. O DeepNPTS discreto, por construção, amostra somente valores de seu contexto. Calculam-

se métricas por localidade e médias não ponderadas entre as dez localidades.

A. DeepNPTS e consolidação de sementes

No DeepNPTS discreto, t denota o último mês observado e $\mathbf{z}_{\ell,t}$ reúne os C valores transformados do contexto da localidade ℓ . Uma rede global combina esse contexto, atributos de tempo e o *embedding* da localidade para definir probabilidades $p_{\ell,t,j}$ sobre suas posições. A função de distribuição acumulada (CDF) preditiva de um passo é

$$\hat{F}_{\ell,t+1}(x) = \sum_{j=1}^C p_{\ell,t,j} \mathbb{I}(z_{\ell,t-C+j} \leq x), \quad \sum_{j=1}^C p_{\ell,t,j} = 1. \quad (2)$$

em que x é um valor de comparação e $\mathbb{I}$ vale 1 quando a condição é verdadeira e 0 caso contrário. Equivalentemente, sorteia-se a posição $J \sim \text{Categorical}(p_{\ell,t,1:C})$ e $\tilde{z}_{\ell,t+1} = z_{\ell,t-C+J}$. A repetição produz amostras e quantis. Trata-se do estimador discreto do GluonTS 0.16.2, com correção local restrita ao registro dos embeddings categóricos no PyTorch. Portanto, o modelo avaliado é o estimador neural não paramétrico, e não um suavizador determinístico por similaridade e recência.

O treinamento minimiza o escore de probabilidade ranqueado (RPS) normalizado implementado pela distribuição discreta do GluonTS, conforme a formulação não paramétrica do modelo [14].

As previsões dos modelos pontuais aprendidos são consolidadas pela média das cinco execuções em cada origem. As referências simples produzem uma única previsão por origem. Para DeepNPTS e DeepAR, as amostras das cinco sementes são reunidas em uma única mistura empírica; a mediana dessa mistura é a previsão pontual, e seus quantis definem os intervalos. Denotando por $\mathcal{S}$ o conjunto de sementes e por B_s o número de amostras por semente, cada distribuição final contém $B = B_s |\mathcal{S}|$ valores, sem primeiro reduzir cada semente a um único ponto.

B. Algoritmo compacto

Algoritmo 1: Treinamento global e avaliação

Entrada: séries $\mathcal{D}$, modelos $\mathcal{M}$, sementes $\mathcal{S}$, contexto $\mathcal{C}$, horizonte h , corte c , níveis Q e origens $\mathcal{O}$.
1: auditar e agregar cada série por mês civil.
2: ajustar a transformação antes de c e construir, para cada arquitetura, entradas causais de contexto $\mathcal{C}$ e horizonte h .
3: para cada $m \in \mathcal{M}$ e $s \in \mathcal{S}$, selecionar a complexidade, quando aplicável, sem usar o teste e ajustar um modelo final global no pré-teste.
4: em cada $o \in \mathcal{O}$, truncar o histórico, prever sem reajuste e inverter a escala com piso zero.
5: consolidar sementes, calcular métricas locais e médias macro e ordenar descritivamente os métodos pelo macro-MAE.
Saída: previsões, amostras, intervalos, métricas e ranking.

III. CONFIGURAÇÃO EXPERIMENTAL E MÉTRICAS

Foram utilizados dados do produto GOES Aggregated PSM v4 da NSRDB [5], [16]. A NSRDB combina informação de satélite e modelos físicos; seus valores são referência modelada, não medição de solo. A consulta original adotou intervalo de 60 minutos, e o projeto preserva médias das 24 horas de cada dia, posteriormente agregadas por mês civil.

As localidades são BYD Camaçari, BMW San Luis Potosí, Ford Rouge, GM Factory Zero, Hyundai Georgia, Lucid Casa Grande, Rivian Normal e Tesla Fremont, Nevada e Texas. Cada série possui 72 meses de 2019 a 2024. Com contexto de 12 meses, os 60 alvos elegíveis cobrem 2020–2024: os 48 primeiros (80%) formam o treinamento (2020–2023), e os 12 últimos (20%), o teste (2024). O ano de 2019 fornece o primeiro contexto. A divisão é cronológica. A janela de 2024 já foi inspecionada durante o desenvolvimento; a análise é retrospectiva e exploratória.

Normalização e quantização em 128 níveis são ajustadas separadamente por localidade. Durante a seleção, seus limites terminam antes da validação; no reajuste final, terminam em dezembro de 2023. As referências simples operam nos valores físicos exatos, enquanto os modelos aprendidos recebem valores quantizados. O teste contém 12 origens *walk-forward*, com horizonte de um mês, e utiliza as sementes 11, 23, 42, 67 e 89. DeepNPTS e DeepAR geram 500 amostras por semente e origem, totalizando 2.500 na mistura. A execução ocorreu sem GPU em Linux 6.8.0-1052-azure, com 2 vCPUs x86_64 e 7,76 GiB de RAM, usando Python 3.12.1, GluonTS 0.16.2, TensorFlow 2.21, Keras 3.15, PyTorch 2.6, scikit-learn 1.9 e XGBoost 3.2.

A. Modelos e hiperparâmetros

A DilatedRNN implementa, de forma customizada, o mecanismo de salto $r_t = \tanh(W_x x_t + W_r r_{t-s} + b)$, em que r_t é o estado recorrente, x_t é a entrada temporal, W_x e W_r são matrizes de pesos, b é o viés e $s \in \{1, 2, 4\}$ é a dilatação. Ela não interpreta colunas tabulares como passos temporais nem constitui reprodução integral da arquitetura original. DeepNPTS e DeepAR partem dos estimadores PyTorch do GluonTS 0.16.2 e usam a localidade como categoria estática. No DeepAR, o contexto 12 e as defasagens 1–12 implicam comprimento passado efetivo de 23 meses, diferença arquitetural mantida na comparação. A Tabela I registra tanto limites de seleção quanto configurações efetivamente usadas; os valores escolhidos podem variar entre sementes.

B. Métricas

Sejam $\mathcal{L}$ o conjunto das dez localidades, $\ell \in \mathcal{L}$ uma localidade, m o modelo e $i = 1, \dots, n_\ell$ o alvo mensal. Denotam-se por $y_{\ell,i}$ a GHI de referência, $\hat{y}_{\ell,i,m}$ a previsão, $\bar{y}_\ell$ a média dos n_ℓ alvos e $e_{\ell,i,m} = y_{\ell,i} - \hat{y}_{\ell,i,m}$ o erro. Calculam-se

$$\text{MAE}_{\ell,m} = n_\ell^{-1} \sum_i |e_{\ell,i,m}|, \quad (3)$$

$$\text{MSE}_{\ell,m} = n_\ell^{-1} \sum_i e_{\ell,i,m}^2, \quad (4)$$

$$\text{RMSE}_{\ell,m} = \sqrt{n_\ell^{-1} \sum_i e_{\ell,i,m}^2}, \quad (5)$$

$$R_{\ell,m}^2 = 1 - \frac{\sum_i e_{\ell,i,m}^2}{\sum_i (y_{\ell,i} - \bar{y}_\ell)^2}, \quad (6)$$

$$\text{nRMSE}_{\ell,m}(\%) = 100 \text{RMSE}_{\ell,m} / \bar{y}_\ell. \quad (7)$$

MAE, MSE e RMSE quantificam o erro pontual; o MAE é o critério primário por sua interpretação direta em W/m², enquanto MSE e RMSE penalizam mais os erros grandes [17]. O MSE é expresso em W²/m⁴, o RMSE em W/m², R^2 é adimensional e o nRMSE expressa o RMSE como percentual da GHI média local. A média não ponderada entre localidades é

$$\overline{\text{MAE}}_m = |\mathcal{L}|^{-1} \sum_{\ell \in \mathcal{L}} \text{MAE}_{\ell,m}. \quad (8)$$

No teste, $m_{\text{rank}} = \arg \min_m \overline{\text{MAE}}_m$ identifica apenas o menor valor observado para o ranking descritivo; ele não participa do ajuste. Para os $S = 5$ ajustes de cada modelo aprendido, seja $\overline{\text{MAE}}_{m,s}$ o macro-MAE da semente s e $\mu_m = S^{-1} \sum_s \overline{\text{MAE}}_{m,s}$. A coluna DP usa o desvio amostral $\text{DP}_m = [(S-1)^{-1} \sum_s (\overline{\text{MAE}}_{m,s} - \mu_m)^2]^{1/2}$.

Omitindo os índices de localidade e modelo, sejam $x_{i,b}$ as B amostras da mistura para o alvo i , com $b, c = 1, \dots, B$, e y_i a referência. O CRPS empírico é

$$\text{CRPS}_i = B^{-1} \sum_b |x_{i,b} - y_i| - (2B^2)^{-1} \sum_b \sum_c |x_{i,b} - x_{i,c}|. \quad (9)$$

Sejam $q_{i,0,05}$ e $q_{i,0,95}$ os quantis preditivos do intervalo central de 90% em cada um dos N alvos. Com $\mathbb{I}$ indicando se o alvo está dentro do intervalo, a cobertura (PICP) e a largura média (MPIW) são

$$\text{PICP}_{90}(\%) = \frac{100}{N} \sum_{i=1}^N \mathbb{I}(q_{i,0,05} \leq y_i \leq q_{i,0,95}), \quad (10)$$

$$\text{MPIW}_{90} = \frac{1}{N} \sum_{i=1}^N (q_{i,0,95} - q_{i,0,05}). \quad (11)$$

CRPS menor indica menor discrepância entre a distribuição preditiva e o valor observado. A PICP deve ser comparada ao nível nominal.

Tabela I
HIPERPARÂMETROS DOS MODELOS APRENDIDOS.

Modelo	Configuração e complexidade efetiva
XGBoost	Profundidade 3; taxa 0,03; <i>subsample</i> =0,8; <i>colsample</i> =0,8; peso mínimo do filho 4; $L_1 = 0, 1$; $L_2 = 10$; métrica MAE; até 1.000 árvores; parada 40. Árvores selecionadas nas sementes: 350, 271, 207, 392 e 242.
MLP	Camadas 64–32; ReLU; L-BFGS; $\alpha = 0, 05$; até 2.000 iterações; padronização interna. Iterações efetivas: 336, 584, 426, 524 e 458.
RNN	SimpleRNN 16 <i>tanh</i> ; concatenação com covariáveis, seguida de densa 16 ReLU; saída linear; Adam 0,001; MSE; lote 32; até 300 épocas; paciência 30. Épocas: 102, 72, 132, 71 e 61.
LSTM	LSTM 16 <i>tanh</i> ; concatenação com covariáveis, seguida de densa 16 ReLU; saída linear; Adam 0,001; MSE; lote 32; até 300 épocas; paciência 30. Épocas: 110, 114, 147, 97 e 109.
DilatedRNN	Três camadas de 16 unidades, dilatações 1–2–4; concatenação com covariáveis, seguida de densa 16 ReLU; saída linear; Adam 0,001; MSE; lote 32; até 300 épocas; paciência 30. Épocas: 72, 146, 21, 104 e 69.
DeepNPTS	Discreto global; contexto 12; camadas 12–12; <i>embedding</i> 5; Adam 10^{-5} ; 100 épocas; 100 lotes/época; lote 32; 500 amostras por semente. Execução efetiva: cinco ajustes novos de 100 épocas, com embeddings registrados.
DeepAR	Duas camadas de 40 unidades; Student- <i>t</i> ; <i>dropout</i> =0,1; defasagens 1–12; sem escalonamento interno; Adam 0,001; 100 épocas; 50 lotes/época; lote 32; paciência 10; 500 amostras por semente. Execução efetiva: cinco ajustes novos de 100 épocas.

A MPIW, expressa em W/m^2 , deve ser analisada junto com a PICP, pois intervalos muito largos podem obter alta cobertura sem boa precisão [18].

IV. RESULTADOS E DISCUSSÃO

A. Comparação média

A Tabela II apresenta as métricas das previsões consolidadas, ordenadas pelo macro-MAE. O desvio entre sementes refere-se ao macro-MAE das cinco execuções e não à dispersão entre localidades.

No protocolo avaliado, a climatologia apresentou o menor macro-MAE, $12,07 W/m^2$, e a persistência, o maior, $35,09 W/m^2$. A redução do melhor em relação ao pior foi de $23,02 W/m^2$ (65,60%). O DeepNPTS obteve $17,70 W/m^2$, ficou em 9º lugar entre 10 métodos, superou apenas a persistência e diferiu da climatologia em $+5,63 W/m^2$. Seu DP foi de $9,22 W/m^2$, indicando forte variabilidade entre sementes. O ranking é descritivo: dez localidades, quatro ciclos anuais de alvos de treinamento e uma única janela de teste não sustentam generalização externa.

B. DeepNPTS por localidade

O menor MAE do DeepNPTS ocorreu em Lucid Casa Grande ($10,79 W/m^2$), e o maior, em Rivian Normal ($25,61 W/m^2$), uma amplitude de $14,82 W/m^2$. Pelo menor MAE local, a LSTM liderou em Ford Rouge, GM Factory Zero, Rivian Normal e Tesla Nevada; a climatologia, em BMW San Luis Potosí, BYD Camaçari e Hyundai Georgia; a RNN, em Tesla Fremont; o DeepAR, em Tesla Texas; e o sazonal ingênuo, em Lucid Casa Grande. O DeepNPTS não liderou nenhuma localidade. Essa contagem posterior ao teste é apenas descritiva e não substitui o critério macro da Eq. (8).

C. Evolução temporal e incerteza

A Fig. 2 reúne a comparação temporal e o intervalo do DeepNPTS em Camaçari. Ele teve menor erro absoluto em fevereiro, maio, julho, agosto, setembro e outubro; a climatologia foi melhor nos outros seis meses e no conjunto do ano. Os MAEs foram $15,74$ e $13,14 W/m^2$, respectivamente. As curvas alternam qual fica mais próxima da referência, sem domínio visual uniforme de um método.




Figura 2. GHI de referência modelada da NSRDB e previsões para a BYD Camaçari em 2024: (a) DeepNPTS e climatologia; (b) distribuição preditiva do DeepNPTS.

Na média entre localidades, o DeepNPTS apresentou CRPS de $15,90 W/m^2$, $PICP_{90}$ de $90,83\%$ e $MPIW_{90}$ de $145,56 W/m^2$; para o DeepAR, os valores foram $10,83 W/m^2$, $61,67\%$ e $35,50 W/m^2$. Assim, o DeepNPTS ficou mais próximo da cobertura nominal, mas o DeepAR obteve menor CRPS; os intervalos do DeepNPTS foram 4,10 vezes mais largos. As três métricas provêm da mistura das amostras das cinco sementes.

D. Limitações

O histórico cobre seis anos, mas somente quatro ciclos fornecem alvos de treinamento.

A janela de 2024 já foi examinada, e cinco sementes capturam somente parte da variabilidade computacional.

Tabela II
MÉTRICAS MÉDIAS ENTRE AS DEZ LOCALIDADES NO TESTE RETROSPECTIVO.

Modelo	MAE W/m ²	DP sementes W/m ²	MSE W ² /m ⁴	RMSE W/m ²	R ²	nRMSE %
Climatologia	12,07	–	241,23	15,32	0,931	7,64
LSTM	12,22	0,20	237,69	15,06	0,919	7,39
RNN	12,55	0,49	262,12	15,59	0,910	7,70
DilatedRNN	13,42	0,83	286,63	16,20	0,898	7,93
DeepAR	14,18	0,90	336,88	17,94	0,892	8,78
XGBoost	14,57	0,14	333,78	17,93	0,892	8,78
MLP	16,06	0,46	418,44	19,77	0,875	9,70
Sazonal ingênuo	16,94	–	496,86	21,37	0,829	10,38
DeepNPTS	17,70	9,22	540,86	22,81	0,847	11,33
Persistência	35,09	–	1808,74	42,17	0,576	20,89

Tabela III
DESEMPENHO PONTUAL DO DEEPNPTS POR LOCALIDADE.

Localidade	MAE W/m ²	MSE W ² /m ⁴	RMSE W/m ²	R ²	nRMSE %
BMW San Luis Potosí	24,52	867,07	29,45	0,571	11,88
BYD Camaçari	15,74	430,18	20,74	0,693	8,78
Ford Rouge	17,26	545,30	23,35	0,909	14,55
GM Factory Zero	17,52	535,54	23,14	0,910	14,44
Hyundai Georgia	16,49	422,69	20,56	0,859	10,37
Lucid Casa Grande	10,79	194,22	13,94	0,965	5,65
Rivian Normal	25,61	944,08	30,73	0,840	17,08
Tesla Fremont	15,57	406,61	20,16	0,954	9,14
Tesla Nevada	15,17	463,62	21,53	0,947	9,69
Tesla Texas	18,33	599,26	24,48	0,820	11,72

As dez localidades foram escolhidas pela presença das fábricas e não constituem amostra espacial aleatória. Além disso, a transformação satura entradas fora dos extremos pré-teste e a quantização discretiza os valores fornecidos aos modelos aprendidos, enquanto as referências simples usam valores físicos exatos. A NSRDB é uma referência modelada, e os dados horários brutos não foram preservados. Os resultados não devem ser extrapolados para geração fotovoltaica, dados industriais ou outras regiões sem nova validação.

V. CONCLUSÕES

Este trabalho avaliou o DeepNPTS discreto na previsão mensal de GHI. Os modelos aprendidos foram ajustados globalmente por semente e avaliados nas mesmas origens retrospectivas.

No protocolo estudado, a climatologia obteve o menor macro-MAE, 12,07 W/m². O DeepNPTS alcançou 17,70 W/m², ficou em 9º lugar entre 10 métodos e superou apenas a persistência. Em relação ao DeepAR, o DeepNPTS teve MAE pontual e CRPS maiores; sua cobertura ficou mais próxima de 90%, mas seus intervalos foram 4,10 vezes mais largos. Esses achados respondem à pergunta experimental nesta janela, sem estabelecer superioridade universal.

Trabalhos futuros devem ampliar o histórico, reservar uma janela prospectiva e avaliar outros horizontes, variáveis meteorológicas, saturação e quantização.

REFERÊNCIAS

- [1] J. Antonanzas et al., “Review of photovoltaic power forecasting,” *Solar Energy*, vol. 136, pp. 78–111, 2016, doi: 10.1016/j.solener.2016.06.069.
- [2] C. Voyant et al., “Machine learning methods for solar radiation forecasting: A review,” *Renewable Energy*, vol. 105, pp. 569–582, 2017, doi: 10.1016/j.renene.2016.12.095.
- [3] D. Yang et al., “History and trends in solar irradiance and PV power forecasting: A preliminary assessment and review using text mining,” *Solar Energy*, vol. 168, pp. 60–101, 2018, doi: 10.1016/j.solener.2017.11.023.
- [4] J. A. Duffie and W. A. Beckman, *Solar Engineering of Thermal Processes*, 4th ed. Hoboken, NJ, USA: Wiley, 2013.
- [5] M. Sengupta et al., “The National Solar Radiation Data Base (NSRDB),” *Renewable and Sustainable Energy Reviews*, vol. 89, pp. 51–60, 2018, doi: 10.1016/j.rser.2018.03.003.
- [6] C. Voyant et al., “Benchmarks for solar radiation time series forecasting,” *Renewable Energy*, vol. 191, pp. 747–762, 2022, doi: 10.1016/j.renene.2022.04.065.
- [7] S. Sobri, S. Koohi-Kamali, and N. A. Rahim, “Solar photovoltaic generation forecasting methods: A review,” *Energy Conversion and Management*, vol. 156, pp. 459–497, 2018, doi: 10.1016/j.enconman.2017.11.019.
- [8] T. Chen and C. Guestrin, “XGBoost: A scalable tree boosting system,” in *Proc. 22nd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- [9] K. Hornik, M. Stinchcombe, and H. White, “Multilayer feedforward networks are universal approximators,” *Neural Networks*, vol. 2, no. 5, pp. 359–366, 1989, doi: 10.1016/0893-6080(89)90020-8.
- [10] J. L. Elman, “Finding structure in time,” *Cognitive Science*, vol. 14, no. 2, pp. 179–211, 1990, doi: 10.1207/s15516709cog1402_1.
- [11] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.
- [12] S. Chang et al., “Dilated recurrent neural networks,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [13] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, “DeepAR: Probabilistic forecasting with autoregressive recurrent networks,” *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020, doi: 10.1016/j.ijforecast.2019.07.001.
- [14] S. S. Rangapuram et al., “Deep non-parametric time series forecaster,” *arXiv preprint arXiv:2312.14657*, 2023, doi: 10.48550/arXiv.2312.14657.
- [15] A. Alexandrov et al., “GluonTS: Probabilistic and neural time series modeling in Python,” *Journal of Machine Learning Research*, vol. 21, no. 116, pp. 1–6, 2020.
- [16] National Laboratory of the Rockies, “GOES Aggregated PSM v4 Download API,” 2026. [Online]. Available: <https://developer.nlr.gov/docs/solar/nsrdb/nsrdb-GOES-aggregated-v4-0-0-download/>. Accessed: Jul. 19, 2026.
- [17] R. J. Hyndman and A. B. Koehler, “Another look at measures of forecast accuracy,” *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: 10.1016/j.ijforecast.2006.03.001.
- [18] T. Gneiting and A. E. Raftery, “Strictly proper scoring rules, prediction, and estimation,” *Journal of the American Statistical Association*, vol. 102, no. 477, pp. 359–378, 2007, doi: 10.1198/016214506000001437.