



Modelagem Computacional no
Sertão Mineiro



PPGMCS
Programa de Pós-Graduação em
Modelagem Computacional e Sistemas

AValiação DO DEEPNPTS E DE MODELOS DE REFERÊNCIA PARA PREVISÃO MENSAL DE IRRADIÂNCIA GLOBAL HORIZONTAL EM LOCALIDADES DE FÁBRICAS DE VEÍCULOS ELÉTRICOS

Gustavo de Melo Nascimento¹ - g239679@dac.unicamp.br

Thales Wulfert Cabral¹ - t264377@dac.unicamp.br

Gustavo Fraidenraich¹ - gfraiden@unicamp.br

¹Faculdade de Engenharia Elétrica e de Computação, Universidade Estadual de Campinas – Campinas, SP, Brasil

Abstract. Este artigo avalia o Deep Non-Parametric Time Series Forecaster (DeepNPTS) na previsão mensal de Irradiância Global Horizontal (GHI), com horizonte de um mês, em dez localidades. Dados da National Solar Radiation Database de 2019–2024 são normalizados e quantizados em 128 níveis com parâmetros pré-teste. O DeepNPTS discreto do GluonTS é comparado a três referências simples e seis modelos aprendidos. O protocolo retrospectivo usa 48 alvos de treinamento, 12 origens de teste por localidade, cinco sementes e parâmetros fixos durante o teste. A **climatologia** obteve o menor MAE médio, **12,07 W/m²**; o DeepNPTS obteve **17,70 W/m²** e ficou em **9º lugar entre 10 métodos**. Para DeepNPTS e DeepAR também se avaliam CRPS e intervalos preditivos de 90%. Os resultados restringem-se à janela estudada.

Keywords: Irradiância solar, GHI, previsão probabilística, séries temporais, DeepNPTS

1. INTRODUÇÃO

A disponibilidade do recurso solar condiciona o desempenho de sistemas fotovoltaicos. Nesse contexto, previsões de irradiância contribuem para reduzir a incerteza associada ao planejamento e à operação, embora sua utilidade dependa do horizonte, da resolução temporal e dos dados disponíveis. Em particular, previsões mensais podem apoiar decisões de médio prazo ao sintetizar a variação sazonal do recurso (Antonanzas et al., 2016; Voyant et al., 2017).

Entre as grandezas empregadas para caracterizar essa disponibilidade, a Irradiância Global Horizontal (GHI) reúne a irradiância difusa e a componente direta projetada sobre uma superfície horizontal (Duffie e Beckman, 2013). Este trabalho prevê a média mensal da GHI, expressa em W/m² e calculada sobre as 24 horas do dia; portanto, o alvo não corresponde à energia gerada. Os dados provêm da National Solar Radiation Database (NSRDB), que combina observações

de satélite e modelos físicos e, por essa razão, fornece uma referência modelada, e não uma medição em solo (Sengupta et al., 2018).

A agregação mensal, contudo, produz apenas doze observações por ano e limita a quantidade de exemplos disponíveis para o treinamento. Essa característica torna especialmente importante comparar modelos flexíveis de aprendizado com referências sazonais simples (Voyant et al., 2017, 2022). Para contemplar diferentes níveis de complexidade, avaliam-se persistência, sazonal ingênuo e climatologia, além de XGBoost, MLP, RNN, LSTM, DilatedRNN, DeepAR e DeepNPTS. Entre os modelos probabilísticos, o DeepAR representa a distribuição preditiva por meio de uma forma contínua parametrizada (Salinas et al., 2020), enquanto o DeepNPTS atribui probabilidades aos valores do contexto observado sem impor essa forma paramétrica (Rangapuram et al., 2023).

Diante desse cenário, o objetivo deste trabalho é verificar, sob um mesmo protocolo experimental, se modelos aprendidos superam referências sazonais na previsão da GHI do mês seguinte. A análise enfatiza a variante discreta do DeepNPTS proposta por Rangapuram et al. (2023) e disponível no GluonTS (Alexandrov et al., 2020); todos os métodos são comparados com os mesmos alvos e as mesmas origens de previsão.

1.1 Principais contribuições

As principais contribuições são: (i) a avaliação experimental do DeepNPTS, treinado globalmente, para a previsão mensal de GHI em dez localidades; (ii) sua comparação com referências sazonais e modelos aprendidos de diferentes níveis de complexidade; e (iii) a aplicação de um protocolo auditável, com cinco sementes e métricas pontuais e probabilísticas. As fábricas servem exclusivamente como pontos de referência geográfica. Em razão do histórico e da janela de teste disponíveis, não se reivindicam pioneirismo, robustez externa ou superioridade universal.

2. SISTEMA E MÉTODO EXPERIMENTAL

A Figura 1 resume o fluxo experimental. Cada bloco é descrito na mesma ordem.




Figura 1: Fluxo do sistema para previsão mensal de GHI.

Dados e auditoria. Verificam-se datas, duplicidades, lacunas, valores não finitos, GHI negativa e metadados. As médias diárias preservadas derivam de consultas da NSRDB com intervalo de 60 minutos e são agregadas por mês civil (Sengupta et al., 2018).

Transformação e entradas. Limites min-max por localidade, sem alvos do teste, saturam e quantizam os valores em 128 níveis. Modelos tabulares recebem 12 defasagens, médias móveis, calendário e localidade; redes recorrentes processam a sequência; DeepNPTS e DeepAR recebem a série transformada e a localidade. A quantização é escolha do protocolo, não requisito do DeepNPTS.

Ajuste e teste. Cada modelo aprendido é global por semente; as referências operam em W/m^2 , sem treinamento. A complexidade é escolhida antes do teste, quando aplicável, e o modelo é reajustado no período pré-teste. Nas 12 origens de 2024, prevê-se o mês seguinte, incorpora-se o valor observado ao contexto e mantêm-se fixos os parâmetros. Portanto, não se preveem os 12

meses conjuntamente. A inversão para W/m^2 usa piso zero, sem teto de treinamento.

2.1 DeepNPTS e consolidação

No DeepNPTS discreto, ℓ identifica a localidade, t o último mês observado e $\mathbf{z}_{\ell,t}$ o contexto com C valores. A rede combina esse contexto, atributos de tempo e o *embedding* da localidade para atribuir probabilidade $p_{\ell,t,j}$ à posição j . A função de distribuição preditiva $\hat{F}$ de um passo é

$$\hat{F}_{\ell,t+1}(x) = \sum_{j=1}^C p_{\ell,t,j} \mathbb{I}(\mathbf{z}_{\ell,t-C+j} \leq x), \quad \sum_{j=1}^C p_{\ell,t,j} = 1. \quad (1)$$

Na Eq. (1), $\mathbb{I}$ vale 1 quando a condição ocorre e 0 caso contrário; x é um valor de comparação. A variante discreta sorteia valores do contexto. No estimador GluonTS 0.16.2, corrige-se apenas o registro dos *embeddings* no PyTorch; arquitetura, distribuição e RPS normalizado permanecem oficiais. Modelos pontuais usam a média das sementes. DeepNPTS e DeepAR reúnem 500 amostras por semente (2.500 por origem) e usam mediana e quantis.

Algoritmo 1: Treinamento global e avaliação

Entrada: séries $\mathcal{D}$, modelos aprendidos $\mathcal{A}$, referências $\mathcal{R}$, sementes $\mathcal{S}$, contexto C , horizonte h , corte c e origens $\mathcal{O}$.

- 1:** auditar e agregar cada série.
- 2:** ajustar transformações antes de c e construir entradas causais.
- 3:** para cada $a \in \mathcal{A}$ e $s \in \mathcal{S}$, ajustar um modelo global sem usar o teste; $\mathcal{R}$ não é treinado.
- 4:** em cada $o \in \mathcal{O}$, prever com $\mathcal{A} \cup \mathcal{R}$ e parâmetros fixos.
- 5:** consolidar as sementes e selecionar $m^* = \arg \min_m \overline{\text{MAE}}_m$.

Saída: previsões, amostras, intervalos, métricas e m^* .

3. CONFIGURAÇÃO E MÉTRICAS

O produto GOES Aggregated PSM v4 da NSRDB cobre o período de 2019 a 2024 nas dez localidades analisadas (National Laboratory of the Rockies, 2026): BYD Camaçari, BMW San Luis Potosí, Ford Rouge, GM Factory Zero, Hyundai Georgia, Lucid Casa Grande, Rivian Normal e Tesla Fremont, Nevada e Texas. O ano de 2019 fornece o contexto inicial; em seguida, os 48 alvos de 2020–2023 compõem o treinamento e os 12 alvos de 2024, o teste, resultando em uma divisão cronológica de 80%/20%. Adota-se um contexto de 12 meses, enquanto as defasagens do DeepAR ampliam seu passado efetivo para 23 meses.

A complexidade dos modelos é selecionada antes do teste e, quando há seleção, realiza-se em seguida um novo ajuste com todo o período pré-teste. Como os dados de 2024 já foram examinados durante o desenvolvimento, a avaliação tem caráter retrospectivo e exploratório. Os experimentos utilizam as sementes 11, 23, 42, 67 e 89 e são executados sem GPU, em Linux 6.8.0-1052-azure, com 2 vCPUs x86_64 e 7,76 GiB de RAM. O ambiente inclui Python 3.12.1, GluonTS 0.16.2, TensorFlow 2.21, Keras 3.15, PyTorch 2.6, scikit-learn 1.9 e XGBoost 3.2.

Sejam ℓ a localidade, m o modelo e $i = 1, \dots, n_\ell$ o mês avaliado. Denotam-se por $y_{\ell,i}$ a GHI de referência, $\hat{y}_{\ell,i,m}$ a previsão, $e_{\ell,i,m} = y_{\ell,i} - \hat{y}_{\ell,i,m}$ o erro e $\bar{y}_\ell$ a média dos n_ℓ alvos. Calculam-se

Tabela 1: Hiperparâmetros dos modelos aprendidos.

Modelo	Configuração
XGBoost	Profundidade 3; taxa 0,03; amostragens 0,8; peso mínimo 4; $L_1 = 0, 1$; $L_2 = 10$; até 1.000 árvores; parada 40.
MLP	Camadas 64–32; ReLU; L-BFGS; $\alpha = 0,05$; até 2.000 iterações.
RNN/LSTM	16 unidades; estado e covariáveis; densa 16 ReLU; Adam 0,001; MSE; lote 32; até 300 épocas; paciência 30.
DilatedRNN	Três camadas de 16; saltos 1–2–4; covariáveis; densa 16 ReLU; Adam 0,001; lote 32; até 300 épocas; paciência 30.
DeepNPTS	Discreto; contexto 12; camadas 12–12; <i>embedding</i> 5; Adam 10^{-5} ; 100 épocas; 100 lotes/época; lote 32; 500 amostras/semte.
DeepAR	Camadas 40–40; Student- <i>t</i> ; <i>dropout</i> 0,1; defasagens 1–12; Adam 0,001; 100 épocas; 50 lotes/época; lote 32; paciência 10; 500 amostras/semte.

$$\begin{aligned}
\text{MAE}_{\ell,m} &= n_{\ell}^{-1} \sum_i |e_{\ell,i,m}|, & \text{MSE}_{\ell,m} &= n_{\ell}^{-1} \sum_i e_{\ell,i,m}^2, \\
\text{RMSE}_{\ell,m} &= \sqrt{n_{\ell}^{-1} \sum_i e_{\ell,i,m}^2}, & R_{\ell,m}^2 &= 1 - \frac{\sum_i e_{\ell,i,m}^2}{\sum_i (y_{\ell,i} - \bar{y}_{\ell})^2}, \\
\text{nRMSE}_{\ell,m}(\%) &= 100 \text{RMSE}_{\ell,m} / \bar{y}_{\ell}.
\end{aligned} \tag{2}$$

O MAE é o critério principal por expressar o erro em W/m²; MSE e RMSE penalizam mais erros grandes, e o RMSE retorna à unidade original (Hyndman e Koehler, 2006). O R^2 descreve a variação acompanhada, e o nRMSE expressa o RMSE como percentual da GHI média. Com $\mathcal{L}$ representando as dez localidades, compara-se $\overline{\text{MAE}}_m = |\mathcal{L}|^{-1} \sum_{\ell \in \mathcal{L}} \text{MAE}_{\ell,m}$. Para os modelos repetidos em $S = 5$ sementes, a coluna DP usa o desvio-padrão amostral $\sqrt{(S-1)^{-1} \sum_s (\overline{\text{MAE}}_{m,s} - \overline{\text{MAE}}_m)^2}$.

DeepNPTS e DeepAR geram B amostras por previsão. Omitindo ℓ e m para simplificar, $x_{i,b}$ e $x_{i,c}$ são as amostras de índices $b, c = 1, \dots, B$. O CRPS empírico é

$$\text{CRPS}_i = B^{-1} \sum_b |x_{i,b} - y_i| - (2B^2)^{-1} \sum_b \sum_c |x_{i,b} - x_{i,c}|. \tag{3}$$

Quanto menor o CRPS, menor a discrepância entre a distribuição preditiva e o valor observado. Se $q_{i;0,05}$ e $q_{i;0,95}$ são os quantis de 5% e 95% e $\mathbb{I}$ vale 1 quando a condição é verdadeira e 0 caso contrário, então

$$\text{PICP}_{90} = \frac{100}{n} \sum_{i=1}^n \mathbb{I}(q_{i;0,05} \leq y_i \leq q_{i;0,95}), \quad \text{MPIW}_{90} = \frac{1}{n} \sum_{i=1}^n (q_{i;0,95} - q_{i;0,05}). \tag{4}$$

O PICP_{90} mede a cobertura percentual, e o MPIW_{90} , a largura média dos intervalos. Cobertura próxima de 90% deve ser analisada junto com a largura, pois intervalos excessivos são pouco informativos (Gneiting e Raftery, 2007).

4. RESULTADOS E DISCUSSÃO

4.1 Comparação média

A Tabela 2 ordena os métodos do menor para o maior MAE médio entre localidades. A coluna DP mostra quanto o MAE médio variou entre as cinco sementes. Portanto, ela não representa a diferença de desempenho entre localidades. O traço nessa coluna indica que a referência simples não foi repetida com sementes.

Tabela 2: Métricas médias entre as dez localidades no teste retrospectivo.

Modelo	MAE W/m ²	DP W/m ²	RMSE W/m ²	R ²	nRMSE %
Climatologia	12,07	–	15,32	0,931	7,64
LSTM	12,22	0,20	15,06	0,919	7,39
RNN	12,55	0,49	15,59	0,910	7,70
DilatedRNN	13,42	0,83	16,20	0,898	7,93
DeepAR	14,18	0,90	17,94	0,892	8,78
XGBoost	14,57	0,14	17,93	0,892	8,78
MLP	16,06	0,46	19,77	0,875	9,70
Sazonal ingênuo	16,94	–	21,37	0,829	10,38
DeepNPTS	17,70	9,22	22,81	0,847	11,33
Persistência	35,09	–	42,17	0,576	20,89

A **climatologia** teve o menor macro-MAE, **12,07 W/m²**; a persistência teve o maior, **35,09 W/m²**, diferença de **23,02 W/m²** (65,60%). O DeepNPTS obteve **17,70 W/m²**, ficou em **9º lugar entre 10 métodos** e superou apenas a persistência. Sua diferença para a climatologia foi **+5,63 W/m²**, com IC95% pareado [**3,76; 7,55**] e $p = \mathbf{0,0176}$ no teste de Wilcoxon após correção de Holm. O DP de **9,22 W/m²** evidencia forte variabilidade entre sementes. Esses resultados se limitam a quatro ciclos anuais de alvos de treinamento e uma janela de teste.


4.2 DeepNPTS por localidade

Tabela 3: Desempenho pontual do DeepNPTS por localidade.

Localidade	MAE W/m ²	RMSE W/m ²	R ²	nRMSE %
BMW San Luis Potosí	24,52	29,45	0,571	11,88
BYD Camaçari	15,74	20,74	0,693	8,78
Ford Rouge	17,26	23,35	0,909	14,55
GM Factory Zero	17,52	23,14	0,910	14,44
Hyundai Georgia	16,49	20,56	0,859	10,37
Lucid Casa Grande	10,79	13,94	0,965	5,65
Rivian Normal	25,61	30,73	0,840	17,08
Tesla Fremont	15,57	20,16	0,954	9,14
Tesla Nevada	15,17	21,53	0,947	9,69
Tesla Texas	18,33	24,48	0,820	11,72

O menor MAE do DeepNPTS ocorreu em **Lucid AMP 1 Casa Grande ($10,79 \text{ W/m}^2$)** e o maior em **Rivian Normal ($25,61 \text{ W/m}^2$)**, amplitude de $14,82 \text{ W/m}^2$. Pelo menor MAE local, a LSTM liderou em quatro localidades, a climatologia em três e RNN, DeepAR e sazonal ingênuo em uma cada; o DeepNPTS, em nenhuma. Essa contagem posterior ao teste é apenas descritiva e não substitui o critério macro.

4.3 Evolução temporal e incerteza



(a) Referência e previsões pontuais.

(b) Mediana e intervalo central de 90%.

Figura 2: GHI de referência modelada e previsões para BYD Camaçari em 2024: (a) DeepNPTS e **Climatologia**; (b) distribuição preditiva do DeepNPTS.

Em Camaçari, as curvas alternam qual fica mais próxima da referência: o DeepNPTS teve menor erro em 6 dos 12 meses, mas a climatologia apresentou melhor sobreposição no conjunto do ano, com MAE de $13,14 \text{ W/m}^2$, contra $15,74 \text{ W/m}^2$.

Na média entre localidades, o DeepNPTS obteve CRPS $15,90 \text{ W/m}^2$, PICP₉₀ $90,83\%$ e MPIW₉₀ $145,56 \text{ W/m}^2$; no DeepAR, foram $10,83 \text{ W/m}^2$, $61,67\%$ e $35,50 \text{ W/m}^2$. O DeepNPTS ficou mais perto da cobertura nominal, mas seus intervalos foram **4,10 vezes mais largos**; o DeepAR teve menor CRPS.

4.4 Limitações

A interpretação dos resultados deve considerar quatro ciclos anuais de alvos de treinamento, cinco sementes e uma única janela de teste, já inspecionada durante o desenvolvimento; por isso, a avaliação é retrospectiva. Além disso, a saturação e a quantização afetam os modelos aprendidos, a NSRDB fornece dados modelados, os registros horários brutos não foram preservados e não se utilizaram dados industriais. Assim, qualquer generalização requer avaliação adicional.

5. CONCLUSÕES

Este trabalho avaliou o DeepNPTS discreto, treinado globalmente, na previsão mensal de GHI. A **climatologia** teve o menor macro-MAE ($12,07 \text{ W/m}^2$). O DeepNPTS obteve $17,70 \text{ W/m}^2$, ficou em **9º lugar entre 10 métodos**, superou apenas a persistência e não liderou localidades; seu menor erro ocorreu em Lucid AMP 1 Casa Grande. Frente ao DeepAR, apresentou MAE e CRPS maiores e intervalos 4,10 vezes mais largos, embora com cobertura mais próxima de 90%.

Os achados não estabelecem superioridade universal. Estudos futuros devem ampliar o histórico, reservar uma janela prospectiva e avaliar outros horizontes, variáveis, saturação e quantização.

Agradecimentos. Os autores agradecem à FAPEMIG (grant n OET-00243-26).

REFERÊNCIAS

- Alexandrov, A. et al. (2020), “GluonTS: Probabilistic and neural time series modeling in Python”, *Journal of Machine Learning Research*, 21(116), 1–6.
- Antonanzas, J. et al. (2016), “Review of photovoltaic power forecasting”, *Solar Energy*, 136, 78–111.
- Duffie, J.A. e Beckman, W.A. (2013), *Solar Engineering of Thermal Processes*, 4^a ed., cap. 1, Wiley.
- Gneiting, T. e Raftery, A.E. (2007), “Strictly proper scoring rules, prediction, and estimation”, *Journal of the American Statistical Association*, 102(477), 359–378.
- Hyndman, R.J. e Koehler, A.B. (2006), “Another look at measures of forecast accuracy”, *International Journal of Forecasting*, 22(4), 679–688.
- National Laboratory of the Rockies (2026), “GOES Aggregated: PSM v4 Download API”. Disponível em: developer.nlr.gov; acesso em: 19 jul. 2026.
- Rangapuram, S.S. et al. (2023), “Deep non-parametric time series forecaster”, *arXiv preprint arXiv:2312.14657*.
- Salinas, D. et al. (2020), “DeepAR: Probabilistic forecasting with autoregressive recurrent networks”, *International Journal of Forecasting*, 36(3), 1181–1191.
- Sengupta, M. et al. (2018), “The National Solar Radiation Data Base (NSRDB)”, *Renewable and Sustainable Energy Reviews*, 89, 51–60.
- Voyant, C. et al. (2017), “Machine learning methods for solar radiation forecasting: A review”, *Renewable Energy*, 105, 569–582.
- Voyant, C. et al. (2022), “Benchmarks for solar radiation time series forecasting”, *Renewable Energy*, 191, 747–762.